

Relatório de I.A.: Redes Neurais (Trabalho 5)

Cauê Baasch de Souza
João Paulo Taylor Ienczak Zanette

26 de Novembro de 2018

1 Resumo do projeto

Linguagem: Python 3.7

Bibliotecas: Foram utilizadas:

- sklearn [1] para modelagem das Redes Neurais;
- pillow [2] para conversão das entradas CSV em imagens para este relatório;
- numpy [3] para representação matricial das entradas.

Configuração	Nº de camadas	Nº de neurônios
1	1	(10)
2	2	(10, 10)
3	2	(10, 100)
4	1	(10)
5	1	(100)
6	1	(200)
7	2	(100, 10)
8	2	(100, 100)
9	2	(200, 100)
10	2	(200, 200)

2 Configuração dos experimentos

Os experimentos foram realizados tomando como base dois conjuntos de dados já disponibilizados pelo professor na plataforma Moodle, sendo um para treinamento da rede neural e outro para testes. Ambos os conjuntos são formados por tuplas no formato $(output, pixel_1, pixel_2, \dots, pixel_n)$, em que $output$ é um número simbolizando a categoria esperada para a análise do conjunto de pixels denotados por $pixel_i$.

O tratamento da rede neural foi separado em duas etapas: uma de treinamento, enviando à rede todas as tuplas do conjunto de treinamento em um grande lote, e outra para testes enviando as tuplas do conjunto de testes e, para cada uma, verificou-se se a previsão da rede foi feita corretamente ou não. Em ambas as etapas, todos os pixels foram normalizados para o intervalo $[0, 1]$ por uma divisão simples (Equação 1).

$$NormPixel_i = \frac{Pixel_i}{255} \quad (1)$$

A arquitetura da rede neural é formada por: uma camada de entrada com número de neurônios dependente do tamanho da entrada; um conjunto de camadas intermediárias com número de camadas variando entre $\{1, 2\}$, cada uma com número de neurônios variando entre $\{10, 100, 200\}$; e uma camada de saída com 10 neurônios (um para cada classificação possível). A Tabela 1 enumera as diferentes configurações de redes neurais para os experimentos.

Quanto ao número de execuções, para fins de avaliação dos resultados foi feito um treinamento e teste para

Tabela 1: Enumeração das configurações de rede neural utilizadas nos experimentos.

cada configuração descrita na Tabela 1, totalizando 10 execuções.

3 Resultados obtidos

3.1 Análise geral

A acurácia das diferentes configurações está expressa na Figura 1. No melhor dos casos, a rede obteve uma acurácia de cerca de 88% para a configuração 9 (2 camadas de 200 e 100 neurônios respectivamente), e no pior caso 78.2% para 1 camada de 10 neurônios.

Na Figura 3 está expressa a matriz de confusão para a configuração 9 quando avaliada para o conjunto de dados de teste. Para referência, a Tabela 2 contém a enumeração das categorias. Considerando quando eram a categoria real, destacam-se Trouser e Shirt como categorias com respectivamente maior (98.4%) e menor acurácia (73.3%), e Shirt e Trouser como categorias de, respectivamente, maior (255) e menor (18) número de falsos positivos.

Um fator interessante pode ser observado na exposição dos resultados: em 246 dos 10000 casos de teste (totalizando 2.46%), a rede não foi capaz de indicar categoria alguma, o que compõe 21.54% das previsões erradas.

É importante apontar o motivo do número alto de falsos positivos de Shirt: dos 255 falsos positivos para essa categoria, 114 ocorreram quando a categoria real era T-




Figura 1: Acurácia da rede neural em diferentes configurações, dada pelo número de acertos dividido pelo número de entradas no conjunto de teste.

Shirt. Assim, é possível perceber que a rede possui dificuldades de separar quando a imagem se trata de um ou de outro por conta de sua semelhança, que é notável no comparativo feito na Figura 2.




Figura 2: Comparativo entre uma das imagens da categoria T-Shirt dada pela rede neural como Shirt (esquerda) e uma das imagens da categoria Shirt dada como T-Shirt (direita). É possível perceber a semelhança das duas imagens quanto ao posicionamento e tamanho das mangas e seu formato.

Retomando a matriz de confusão, é possível notar que há uma correlação de que, dadas duas categorias distintas A e B, quando muitos objetos da categoria A são previstos como da categoria B, então provavelmente muitos objetos da categoria B também serão previstos como da categoria A. Essa correlação permite entender os falsos positivos da rede neural e concluir que há características muito semelhantes entre as categorias, fazendo com que a matriz de confusão se torne próxima de uma matriz

Nº	Categoria
0	T-shirt/top
1	Trouser
2	Pullover
3	Dress
4	Coat
5	Sandal
6	Shirt
7	Sneaker
8	Bag
9	Ankle boot

Tabela 2: Relação entre números das categorias e suas respectivas descrições.

simétrica.




Figura 3: Matriz de confusão para uma rede neural de 2 camadas de 100 neurônios cada.

3.2 Análise de Overfitting

Para perceber o efeito de *Overfitting* (quando a rede neural acaba por descrever os dados de treinamento em vez de descrever o comportamento do problema), foi analisada a acurácia das configurações 1 e 9 para os dados de treinamento e teste, expressa na Figura 4.

Observando o gráfico, é possível verificar que, apesar da acurácia para o conjunto de treinamento ter tido um aumento absoluto de 17% em relação às configurações 1 e 9 (15.5% de aumento relativo), o aumento absoluto para o conjunto de dados de teste foi de apenas 6% (au-




Figura 4: Acurácia das configurações 1 e 9 para os dados de treinamento e teste, demonstrando o efeito de Over-fitting.

mento relativo de 6.8%). Analisando as configurações separadamente, a configuração 1 teve um decréscimo de acurácia de cerca de apenas 3% ao se passar do conjunto de treinamento para o conjunto de teste, enquanto na configuração 9 esse decréscimo foi de cerca de 10%.

Referências

- [1] scikit-learn: Machine Learning in Python. <https://scikit-learn.org/>.
- [2] Pillow — ReadTheDocs. <https://pillow.readthedocs.io/en/5.3.x/>.
- [3] NumPy. <http://www.numpy.org/>.